

# Redes Neurais e Aprendizagem Profunda

## APRENDIZADO DE MÁQUINA FUNÇÃO DE PERDA (I)

---

Zenilton K. G. Patrocínio Jr

[zenilton@pucminas.br](mailto:zenilton@pucminas.br)

# Função de Perda

Pode **não haver** um valor alvo  $y$  “verdadeiro” para uma observação  $x$ , ou seja,  
pode haver vários “diferentes” valores de  $y$  para o mesmo  $x$

# Função de Perda

Pode **não haver** um valor alvo  $y$  “verdadeiro” para uma observação  $x$ , ou seja,  
pode haver vários “diferentes” valores de  $y$  para o mesmo  $x$

Também **pode haver ruído ou efeitos não modelados no conjunto de dados**;  
portanto, mesmo se houver um único  $y$  para um dado  $x$ , pode ser **impossível**  
**predizê-lo com exatidão**

# Função de Perda

Pode **não haver um valor alvo  $y$  “verdadeiro” para uma observação  $x$** , ou seja,  
pode haver vários “diferentes” valores de  $y$  para o mesmo  $x$

Também **pode haver ruído ou efeitos não modelados no conjunto de dados**;  
portanto, mesmo se houver um único  $y$  para um dado  $x$ , pode ser **impossível  
predizê-lo com exatidão**

Em vez disso, tenta-se predizer um valor “próximo” do valor alvo observado

# Função de Perda

Neste caso, usa-se durante o treinamento uma **função de perda** para medir a proximidade de tais previsões feitas em relação aquelas do conjunto de dados que foram previamente observadas

# Função de Perda

Neste caso, usa-se durante o treinamento uma **função de perda** para medir a proximidade de tais previsões feitas em relação aquelas do conjunto de dados que foram previamente observadas

Uma **função de perda** mede a diferença entre uma previsão do valor alvo e o valor disponível no conjunto de treinamento

# Função de Perda

Neste caso, usa-se durante o treinamento uma **função de perda** para medir a proximidade de tais previsões feitas em relação aquelas do conjunto de dados que foram previamente observadas

Uma **função de perda** mede a diferença entre uma previsão do valor alvo e o valor disponível no conjunto de treinamento

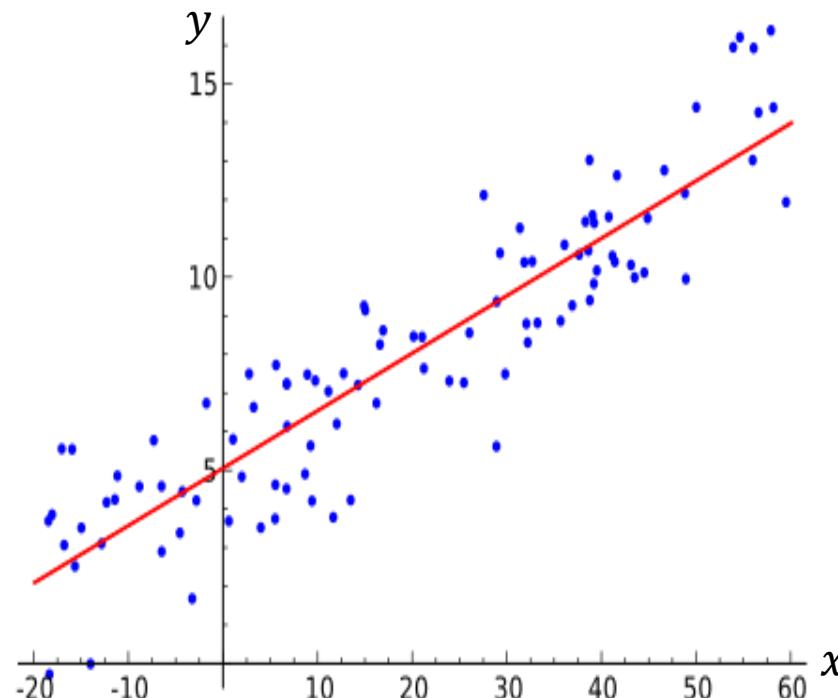
**Exemplo:** Perda quadrática (ou “**squared loss**”)  $L_2(\hat{y}, y) = (\hat{y} - y)^2$  em que  $\hat{y} = f(x)$  representa a previsão feita pelo modelo para o par de dados  $(x, y)$

# Exemplo – Regressão Linear

Nesse tipo de modelo bem simples,  $\hat{y} = f(x) = ax + b$  sendo  $x$  um valor real, enquanto  $a$  e  $b$  são constantes reais

# Exemplo – Regressão Linear

Nesse tipo de modelo bem simples,  $\hat{y} = f(x) = ax + b$  sendo  $x$  um valor real, enquanto  $a$  e  $b$  são constantes reais



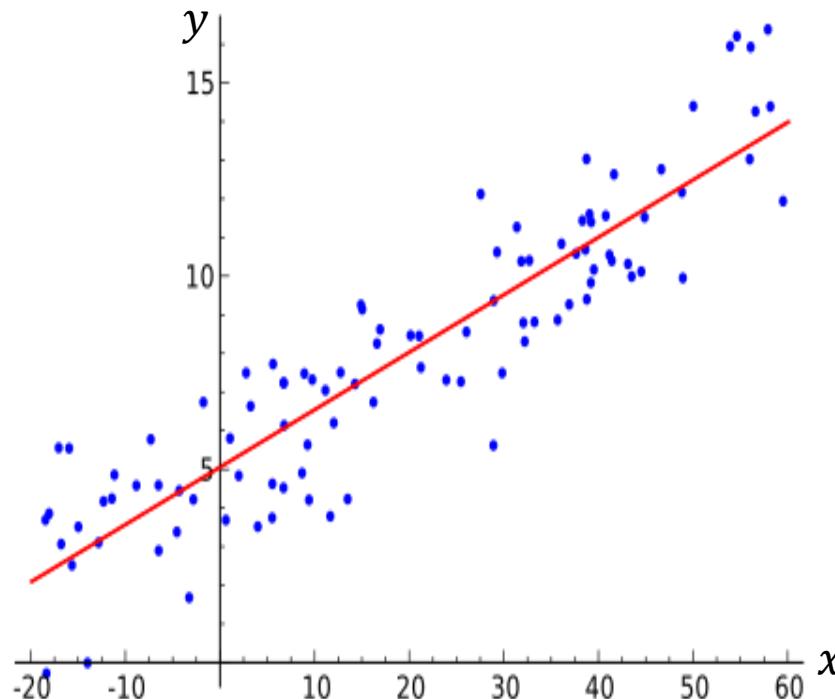
Os  $n$  pares de dados  $(x, y)$   
são os pontos **azuis**

Já o modelo é representado  
pela linha **vermelha**

# Exemplo – Regressão Linear

Nesse tipo de modelo bem simples,  $\hat{y} = f(x) = ax + b$  sendo  $x$  um valor real, enquanto  $a$  e  $b$  são constantes reais

A perda quadrática  $L_2(\hat{y}, y) = (\hat{y} - y)^2$  avalia a diferença (ou distância) entre predição  $\hat{y}$  e dado  $y$



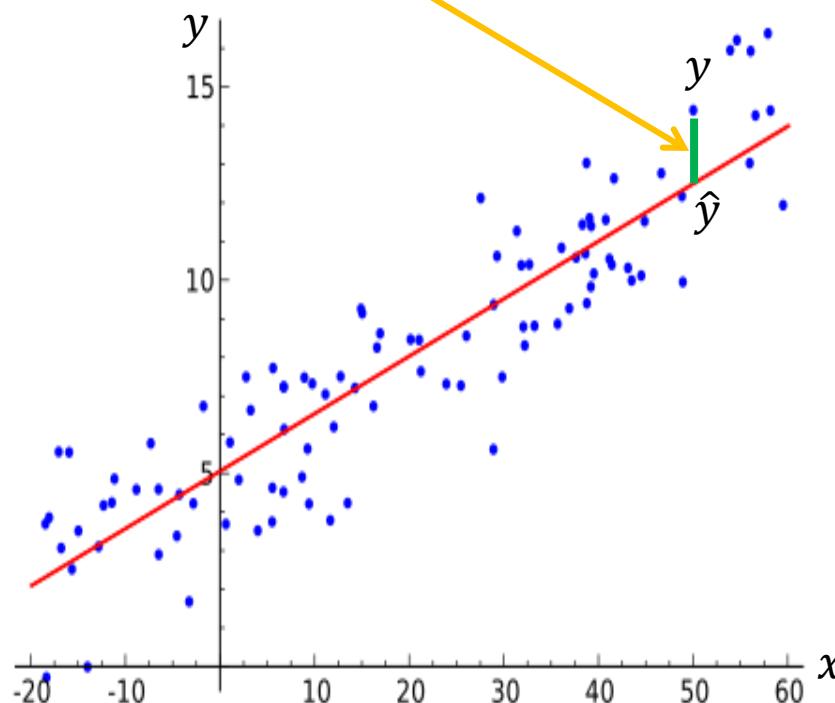
Os  $n$  pares de dados  $(x, y)$  são os pontos azuis

Já o modelo é representado pela linha vermelha

# Exemplo – Regressão Linear

Nesse tipo de modelo bem simples,  $\hat{y} = f(x) = ax + b$  sendo  $x$  um valor real, enquanto  $a$  e  $b$  são constantes reais

A perda quadrática  $L_2(\hat{y}, y) = (\hat{y} - y)^2$  avalia a diferença (ou distância) entre predição  $\hat{y}$  e dado  $y$



Os  $n$  pares de dados  $(x, y)$  são os pontos azuis

Já o modelo é representado pela linha vermelha

# Exemplo – Regressão Linear

A perda total pode ser obtida somando-se a perda em todos os  $n$  pares

$$L = \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

# Exemplo – Regressão Linear

A perda total pode ser obtida somando-se a perda em todos os  $n$  pares

$$L = \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

Uma vez que a predição  $\hat{y}_i$  para um  $x_i$  qualquer é dada por  $ax_i + b$ , pode-se rescrever a perda total como

$$L = \sum_{i=1}^n (ax_i + b - y_i)^2$$

# Exemplo – Regressão Linear

A perda total pode ser obtida somando-se a perda em todos os  $n$  pares

$$L = \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

Uma vez que a predição  $\hat{y}_i$  para um  $x_i$  qualquer é dada por  $ax_i + b$ , pode-se rescrever a perda total como

$$L = \sum_{i=1}^n (ax_i + b - y_i)^2$$

Para se encontrar os valores ótimos de  $a$  e  $b$ , pode-se aplicar o cálculo diferencial, igualando à zero as derivadas da perda total em relação a  $a$  e  $b$ , isto é

$$\frac{dL}{da} = 0 \quad \text{e} \quad \frac{dL}{db} = 0$$

# Exemplo – Regressão Linear

Dessa forma, para se minimizar a perda e obter os valores ótimos de  $a$  e  $b$ , deve-se fazer

$$\frac{dL}{da} = 2a \sum_{i=1}^n x_i^2 + 2b \sum_{i=1}^n x_i - 2 \sum_{i=1}^n x_i y_i = 0$$

$$\frac{dL}{db} = 2a \sum_{i=1}^n x_i + 2bn - 2 \sum_{i=1}^n y_i = 0$$

# Exemplo – Regressão Linear

Dessa forma, para se minimizar a perda e obter os valores ótimos de  $a$  e  $b$ , deve-se fazer

$$\frac{dL}{da} = 2a \sum_{i=1}^n x_i^2 + 2b \sum_{i=1}^n x_i - 2 \sum_{i=1}^n x_i y_i = 0$$

$$\frac{dL}{db} = 2a \sum_{i=1}^n x_i + 2bn - 2 \sum_{i=1}^n y_i = 0$$

Como os somatórios nessas equações são constantes para os  $n$  pares de dados, tem-se duas equações **lineares** em  $a$  e  $b$ , que podem ser facilmente resolvidas

# Exemplo – Regressão Linear

Dessa forma, para se minimizar a perda e obter os valores ótimos de  $a$  e  $b$ , deve-se fazer

$$\frac{dL}{da} = 2a \sum_{i=1}^n x_i^2 + 2b \sum_{i=1}^n x_i - 2 \sum_{i=1}^n x_i y_i = 0$$

$$\frac{dL}{db} = 2a \sum_{i=1}^n x_i + 2bn - 2 \sum_{i=1}^n y_i = 0$$

Como os somatórios nessas equações são constantes para os  $n$  pares de dados, tem-se duas equações **lineares** em  $a$  e  $b$ , que podem ser facilmente resolvidas

O modelo  $f(x) = ax + b$  com estes valores é o **modelo de perda mínima**

# Minimização de Risco

**Recapitulando...** obteve-se o valor das constantes  $a$  e  $b$  que minimizam a perda quadrática sobre alguns dados que ***nós já possuíamos***

# Minimização de Risco

**Recapitulando...** obteve-se o valor das constantes  $a$  e  $b$  que minimizam a perda quadrática sobre alguns dados que **nós já possuíamos**

Porém o que se quer na verdade é predizer os valores de  $y$  para observações  $x$  que **nós ainda não dispomos**, isto é, gostaríamos de minimizar a perda esperada sobre novos dados, ou ainda,  $\mathbb{E}[(\hat{y} - y)^2]$

# Minimização de Risco

**Recapitulando...** obteve-se o valor das constantes  $a$  e  $b$  que minimizam a perda quadrática sobre alguns dados que **nós já possuíamos**

Porém o que se quer na verdade é predizer os valores de  $y$  para observações  $x$  que **nós ainda não dispomos**, isto é, gostaríamos de minimizar a perda esperada sobre novos dados, ou ainda,  $\mathbb{E}[(\hat{y} - y)^2]$

Tal perda esperada é denominada **risco**

# Minimização de Risco

Na verdade, minimizou-se um valor de perda obtido sobre um número finito de dados disponíveis que é chamado de **risco empírico**

# Minimização de Risco

Na verdade, minimizou-se um valor de perda obtido sobre um número finito de dados disponíveis que é chamado de **risco empírico**

Dessa forma, o aprendizado de máquina aproxima modelos que minimizam o risco por meio de modelos que minimizem o risco empírico

# Minimização de Risco

Na verdade, minimizou-se um valor de perda obtido sobre um número finito de dados disponíveis que é chamado de **risco empírico**

Dessa forma, o aprendizado de máquina aproxima modelos que minimizam o risco por meio de modelos que minimizem o risco empírico

Geralmente, minimizar o risco empírico (perda de dados) em vez do risco real funciona bem, mas pode falhar se:

- A amostra de dados for enviesada, ou
- Não houver dados suficientes para estimar com precisão os parâmetros do modelo