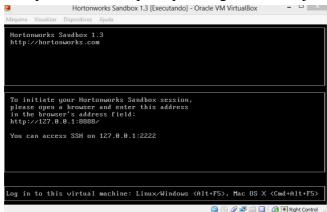
Professor: Cláudio Lúcio

Atividade para acesso ao Spark Shell (Python e Scala)

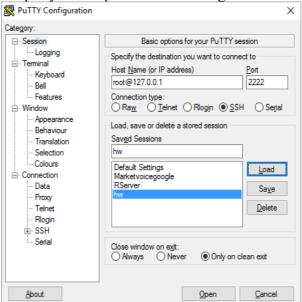
1) Para acesso ao Shell do Spark vamos usar a versão do Spark que vem na máquina virtual do HortonWorks:

Esta é a versão 2.3.2 do produto e pode ser obtida em: http://hortonworks.com/products/hortonworks-sandbox/

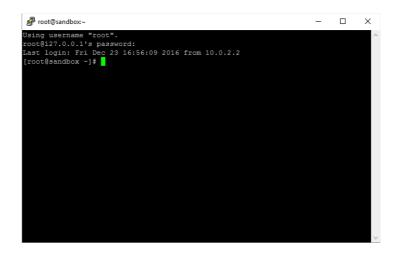
2) Inicialize a máquina virtual. Espere que a seguinte tela seja exibida:



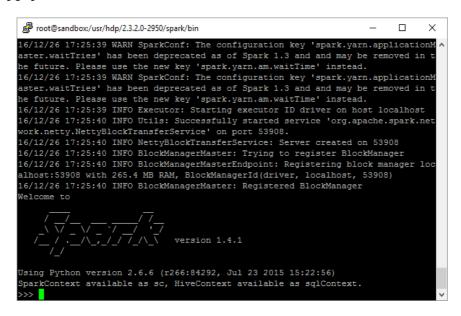
- 3) A recomendação é usar um cliente para acesso SSH ao servidor do spark. Baixe a ferramenta putty.exe;
- 4) Configure o acesso do putty ao máquina virtual da seguinte maneira:



5) Clique em "Open" e então digite a senha do Root: hadoop



- 6) Primeiramente vamos interagir com a interface python para o Spark, para tal vamos acessar o bin/pyspark:
- 7) Digite os seguintes comandos:
 - cd /usr/hdp/2.3.2.0-2950/spark/bin
 - pyspark



- 8) Veja que estamos com a versão 1.4.1 do Spark;
- 9) Por padrão as mensagens de log apresentadas no spark são muito detalhadas e podem dificultar as tarefas de manipulação de dados; Vamos ajustar os logs que serão apresentados. Vamos editar o arquivo ../conf/log4j.properties:
 - cd ..
 - cd conf/
 - vi log4j.properties
 - Pressione a tecla "insert"
 - Altere:

```
# Set everything to be logged to the console
log4j.appender.console=org.apache.log4j.ConsoleAppender
log4j.appender.console.target=System.err
log4j.appender.console.target=System.err
log4j.appender.console.layout=org.apache.log4j.PatternLayout
log4j.appender.console.layout.ConversionFattern=%d(yy/MM/dd HH:mm:ss) %p %c(1):
%m%n

# Settings to quiet third party logs that are too verbose
log4j.logger.org.eclipse.jetty=WARN
log4j.logger.org.eclipse.jetty.util.component.AbstractLifeCycle=ERROR
log4j.logger.org.apache.spark.repl.SparkIMain%exprTyper=INFO
log4j.logger.org.apache.spark.repl.SparkILoop$SparkILoopInterpreter=INFO
```

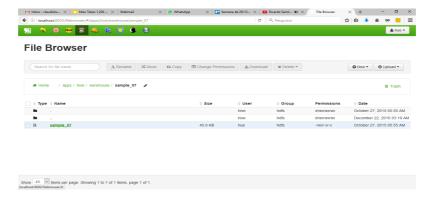
■ Para:

```
# Set everything to be logged to the console
log4j.rootCategory=ERROR, console
log4j.appender.console=org.apache.log4j.ConsoleAppender
log4j.appender.console.target=System.err
log4j.appender.console.layout=org.apache.log4j.PatternLayout
log4j.appender.console.layout.ConversionPattern=%d{yy/MM/dd HH:mm:ss} %p %c{1}:
%m%n

# Settings to quiet third party logs that are too verbose
log4j.logger.org.eclipse.jetty=WARN
log4j.logger.org.eclipse.jetty.util.component.AbstractLifeCycle=ERROR
log4j.logger.org.apache.spark.repl.SparkIMain%exprTyper=INFO
log4j.logger.org.apache.spark.repl.SparkILoop%SparkILoopInterpreter=INFO
```

- Aperte a tecla "ESC"
- Aperte agora as teclas ":wq" e depois "ENTER"
- Digite agora cd ..
- bin/pyspark

10) Vamos agora listar um programa simples para entendimento do pyspark Veja o seguinte arquivo de exemplo do HIVE que esta no HDFS:



11) O seguinte programa Spark acesso o arquivo listado anteriormente:

- lines=sc.textFile("/apps/hive/warehouse/sample_07/sample 07")
- lines.count()
- lines.first()

■ Digite CTRL + Z

12) Vamos agora acessar a interface usando o Scala e executar a mesma tarefa:

o Digite /bin/spark-shell

