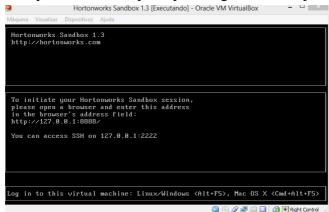
Professor: Cláudio Lúcio

Atividade Verificando processos e RDD's

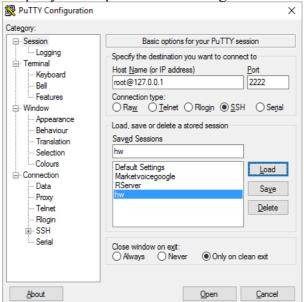
 Para acesso ao Shell do Spark vamos usar a versão do Spark que vem na máquina virtual do HortonWorks:

Esta é a versão 2.3.2 do produto e pode ser obtida em: http://hortonworks.com/products/hortonworks-sandbox/

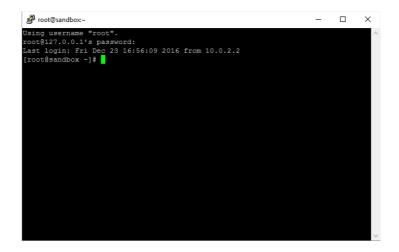
2) Inicialize a máquina virtual. Espere que a seguinte tela seja exibida:



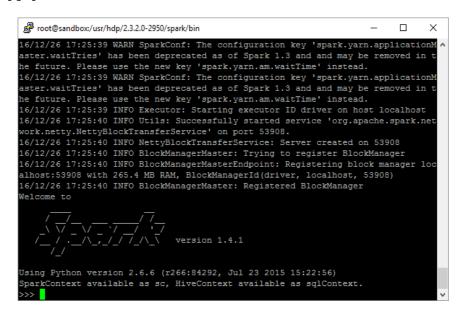
- 3) A recomendação é usar um cliente para acesso SSH ao servidor do spark. Baixe a ferramenta putty.exe;
- 4) Configure o acesso do putty ao máquina virtual da seguinte maneira:



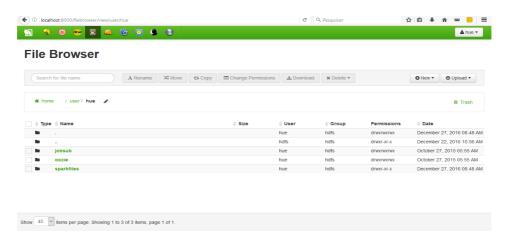
5) Clique em "Open" e então digite a senha do Root: hadoop



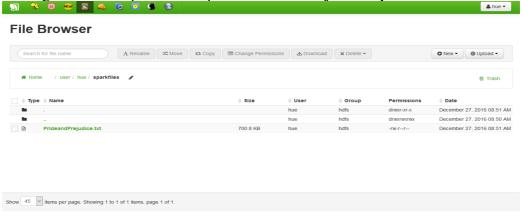
- 6) Primeiramente vamos interagir com a interface python para o Spark, para tal vamos acessar o bin/pyspark:
- 7) Digite os seguintes comandos:
 - cd /usr/hdp/2.3.2.0-2950/spark/bin
 - pyspark



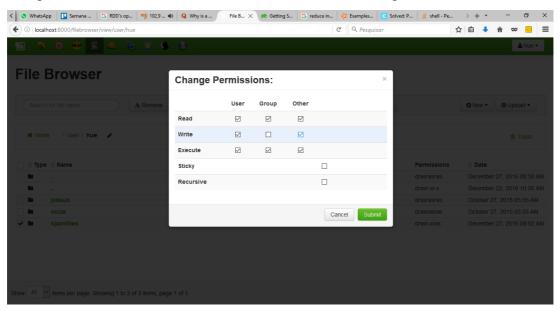
- 8) Veja que estamos com a versão 1.4.1 do Spark;
- 9) Vamos agora fazer o upload de arquivo para o HDFS e posteriormente vamos processá-lo utilizando um programa Spark. Crie uma pasta chamada *sparkfiles* no diretório do usuário Hue:



10) Vamos agora fazer o upload do arquivo *PrideandPrejudice.zip*



- 11) Adicione o direito de outros usuários escreverem neste diretório.
- 12) Marque o checkbox do diretório e clique no botão 'Change permissions'
- 13) Marque o checkbox da linha 'Write' e da coluna 'Other' e clique no botão 'submit'



- 14) Vamos agora entrar no pySpark e trabalhar com este arquivo
- 15) Veja o programa abaixo:

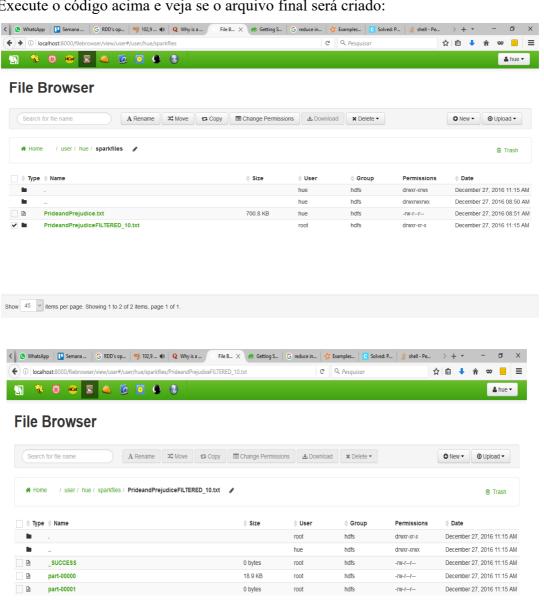
```
tokenized = sc.textFile('/user/hue/sparkfiles/PrideandPrejudice.txt').flatMap(lambda line:
line.split(" "))

allStopWords={'about':1, 'above':1, 'after':1, 'again':1, 'against':1, 'all':1, 'am':1,
    'an':1, 'and':1, 'any':1, 'are':1, 'arent':1, 'as':1, 'at':1, 'be':1, 'because':1, 'been':1,
    'before':1, 'being':1, 'below':1, 'between':1, 'both':1, 'but':1, 'by':1, 'cant':1,
    'cannot':1, 'could':1, 'couldnt':1, 'did':1, 'didnt':1, 'do':1, 'does':1, 'doesnt':1,
    'doing':1, 'dont':1, 'down':1, 'during':1, 'each':1, 'few':1, 'for':1, 'from':1, 'further':1,
    'had:1, 'hadnt':1, 'has':1, 'hasnt':1, 'have':1, 'havent':1, 'having':1, 'he':1, 'he':1,
    'had:1, 'how':1, 'her':1, 'here':1, 'heres':1, 'hers':1, 'herself':1, 'him':1, 'himself':1,
    'his':1, 'how':1, 'isnt':1, 'it':1, 'itl':1, 'itl':1, 'itve':1, 'itee':1, 'in':1,
    'most':1, 'mustnt':1, 'my':1, 'myself':1, 'no':1, 'nor':1, 'not':1, 'off':1, 'on':1,
    'once':1, 'only':1, 'or':1, 'other':1, 'ought':1, 'our':1, 'ourselves':1, 'out':1,
    'shouldnt':1, 'so':1, 'some':1, 'such':1, 'than':1, 'that':1, 'thats':1, 'the':1, 'their':1,
    'theirs':1, 'them':1, 'theyre':1, 'then':1, 'there':1, 'theres':1, 'these':1, 'they':1,
    'theyd':1, 'theyll':1, 'theyre':1, 'theyve':1, 'this':1, 'those':1, 'through':1, 'to':1,
    'well':1, 'were':1, 'were':1, 'were':1, 'wassl':1, 'wasnl':1, 'whom':1, 'whens':1,
    'whom':1, 'whore':1, 'while':1, 'whose':1, 'whom':1, 'whom':1, 'whys':1,
    'while':1, 'would':1, 'yourself':1, 'yourselves':1}
```

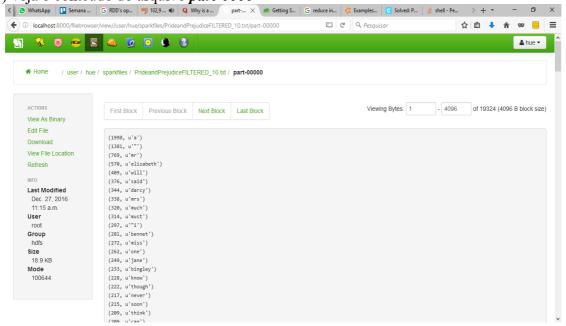
```
# contar a ocorrencia das palavras com alguns tratamentos
wordCounts = tokenized.map( lambda x: x.replace(',',' ').replace('.',' ').replace('-','
').lower()) \
        .flatMap(lambda x: x.split()) \
        .filter(lambda x: x not in allStopWords ) \
        .map(lambda x: (x, 1)) \
        .reduceByKey(lambda x,y:x+y) \
        .map(lambda x:(x[1],x[0])) \setminus
        .sortByKey(False)
wordCounts.cache()
wordCounts.count()
wordCounts.take(10)
threshold = 10
filtered = wordCounts.filter(lambda pair:pair[0] >= threshold)
filtered.count()
filtered.first()
filtered.saveAsTextFile("/user/hue/sparkfiles/PrideandPrejudiceFILTERED "+str(threshold)
+".txt")
```

16) Execute o código acima e veja se o arquivo final será criado:

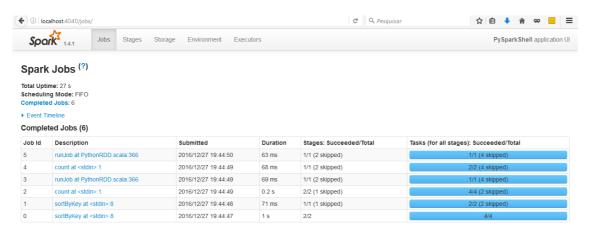
Show 45 vitems per page. Showing 1 to 3 of 3 items, page 1 of 1.



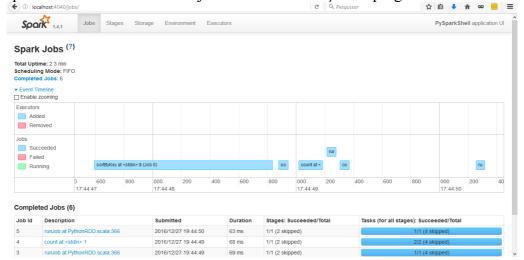
17) Veja o conteúdo do arquivo part-0000



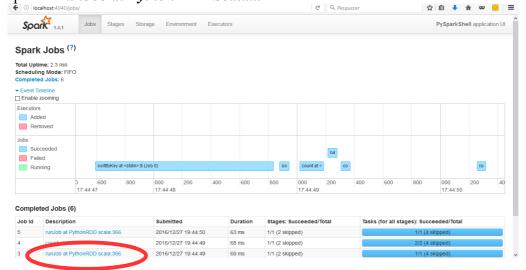
18) Quando o pyspark é utilizado, de maneira local, como neste exemplo o Spark irá também apresentar uma interface para visualizar os jobs submetidos. Digite o endereço http://localhost:4040 no browser:



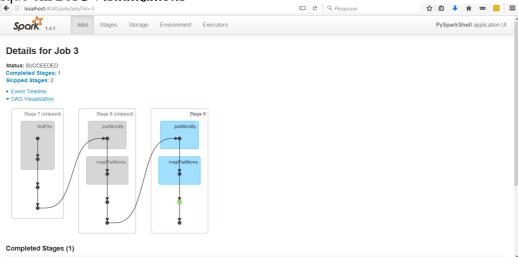
19) Clique no link 'Event Time ' e veja a ordem de execução do programa



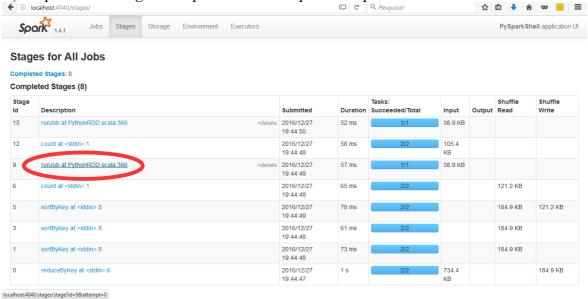
20) Clique em runJob at PythonRDD Scala...



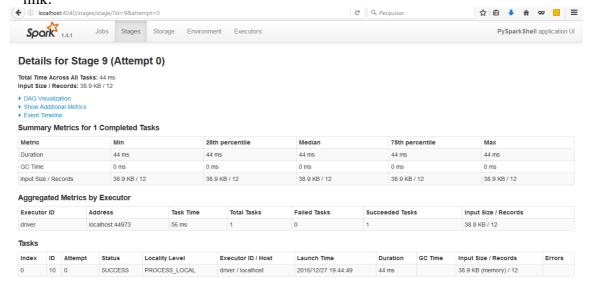
21) Clique em **DAG Visualizations**



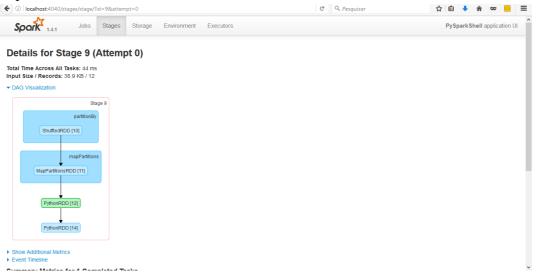
22) Clique na aba 'Stages' em que cada um dos passos é apresentado de forma mais detalhada:



23) Agora veja os detalhes da primeira execução *runJob at PythonRDD Scala...* Clique neste link:



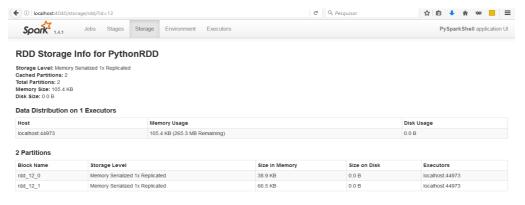
24) Clique no item **DAG Visualization**



25) Outra visualização é dos RDD's, clique em 'Storage'



26) Clique em Python RDD para ver as partições:



27) Por ultimo apague todo o diretório criado, utilizando seguinte linha de comando:

hadoop fs -rmr /user/hue/sparkfiles ou
hadoop fs rm -r /user/hue/sparkfiles